FACULDADE DE TECNOLOGIA DE OURINHOS – FATEC

RAMON LUIS SANCHES, NICOLLAS GERMANO KRATKY, JOÃO VICTOR NETTO ARAUJO, RAFAEL CARBONERA

TASK 2

Processamento com NTLK e spaCy

OURINHOS

2026

Sumário

1. Introdução 3
2. Metodologia 3
3. Resultados 3
3.1 POS-TAG 4
3.2 NER 5
3.3 Dependências Sintáticas 6
3.4 Pipeline 7
3.5 Análise Completa 7
4. Discussão 7
4.1 Limitações da abordagem 8
5. Conclusão 8

1. INTRODUÇÃO

A presente tarefa prática, foi desenvolvida a partir do dataset: *portuguese-poems.csv*, retirado do Kaggle, que contém as seguintes colunas: **Author**, **Title**, **Content** e **Views**, representando, respectivamente, o nome do autor, o título da obra, o texto do poema e o número de visualizações.

O objetivo deste trabalho explorar os pipelines de processamento de linguagem natural, utilizando as bibliotecas: **NLTK** e **spaCy**. Ademais, comparar as diferenças das abordagens diferentes entre ambas as bibliotecas.

2. METODOLOGIA

Para o desenvolvimento deste trabalho, serão realizadas as seguintes etapas: inicialmente, será selecionado um texto, ambas as bibliotecas realizarão o processo de tokenização e tratamento de dados. Entretanto, a etapa de normalização de dados será feita de duas maneiras diferentes, sendo elas, Steamming e Lematização.

Primeiramente, o processo será feito pela biblioteca NLTK, utilizando método Steamming, em seguida, spaCy utilizará a técnica de Lematização. Visando buscar as diferenças entre as duas bibliotecas, será mostrado o comportamento dos tokens em diferentes partes do tratamento de dados em ambas.

3. RESULTADOS

Após realizar as etapas de tratamento de dados no mesmo texto, utilizado diferentes técnicas, chegamos ao seguinte resultado:

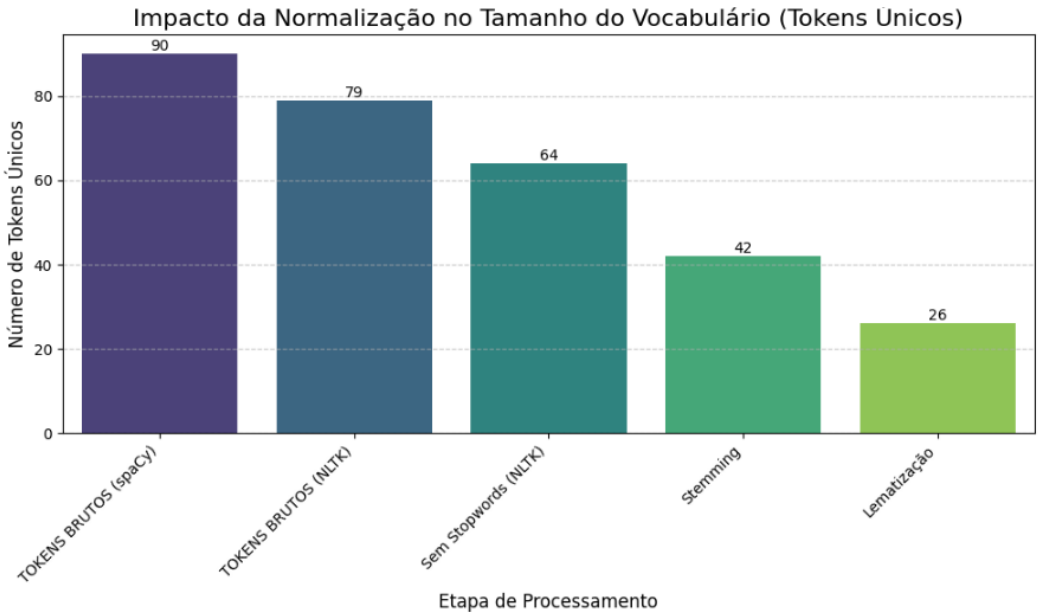

Ao realizar a tokenização, as bibliotecas tiveram o seguinte comportamento: NLTK gerou 79 tokens, enquanto spaCy gerou 90, apresentando um aumento de 28,57% no número de Tokens em relação à NLTK.

Mas quando comparados os métodos de Limpeza e Normalização com Stopwords, Stemming e Lematização. A biblioteca NLTK utilizando Stemming teve redução de 37 tokens, ou seja, uma redução de aproximadamente 41%. Enquanto isso, spaCy utilizando a técnica de lematização, teve uma redução de 64 Tokens, sendo equivalente a uma redução cerca de 71% do número bruto de tokens.

3.1 POS-TAG

POS-TAG é uma técnica de marcação gramatical, que consiste em marcar a uma palavra no texto como correspondente a uma classe gramatical específica. Estes foram os resultados da aplicação com as diferentes bibliotecas:

```
POS-TAGGING NLTK - Primeiros 20 tokens:
   1. eu           → NN
   2. não          → CC
   3. tinha        → JJ
   4. este         → NN
   5. rosto        → NN
   6. de           → IN
   7. hoje         → FW
   8. assim        → JJ
   9. calmo        → NN
  10. assim        → NN
  11. triste       → NN
  12. assim        → NN
  13. magro        → NN
  14. nem          → NN
  15. estes        → VBZ
  16. olhos        → JJ
  17. tão          → JJ
  18. vazios       → NNS
  19. nem          → VBP
  20. o            → JJ
```

```
POS-TAGGING spaCy - Primeiros 20 tokens:
   1. Eu           → PRON  (PRON)
   2. não          → ADV   (ADV)
   3. tinha        → VERB  (VERB)
   4. este         → DET   (DET)
   5. rosto        → NOUN  (NOUN)
   6. de           → ADP   (ADP)
   7. hoje         → ADV   (ADV)
  10. Assim        → ADV   (ADV)
  11. calmo        → ADJ   (ADJ)
  13. assim        → ADV   (ADV)
  14. triste       → VERB  (VERB)
  16. assim        → ADV   (ADV)
  17. magro        → ADJ   (ADJ)
  20. Nem          → ADV   (ADV)
```

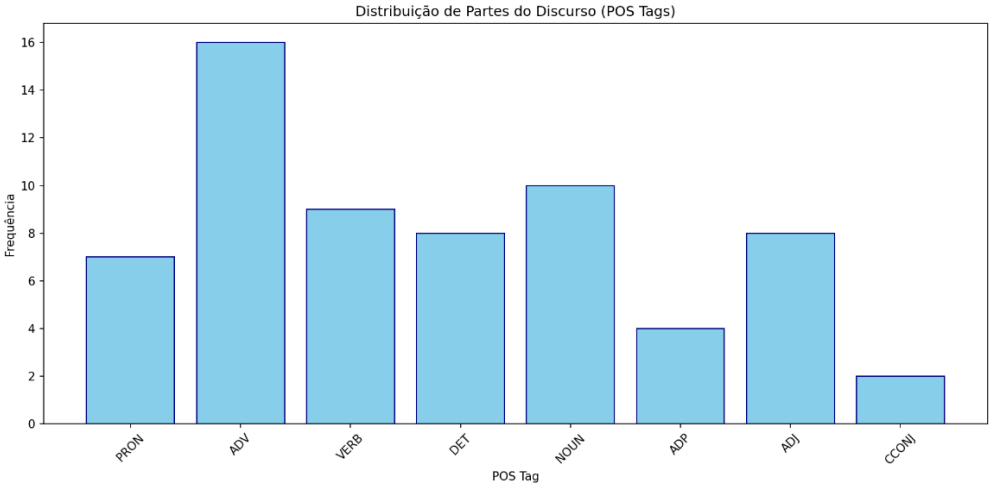

3.2 NER

O reconhecimento de entidades mencionadas (NER) é uma técnica de processamento de linguagem natural, que busca extrair e classificar as entidades mencionadas em um texto. A técnica foi aplicada com 5 poemas dos seguintes autores: **Fernando Pessoa, Cecília Meireles, Carlos Drummond de Andrade** e **Vinicius de Moraes.** Obteve-se os seguintes resultados:

Fernando Pessoa:
Entidades encontradas: Bojador Tem, Vejo, O íntimo, Porque, Valeu, Portugal, De, Quantos, Vale, Teu.

Cecília Meireles:
Entidades encontradas: Tão paradas e frias e mortas, Tão, Pardais, Pensei, Lope de Vega, Minhas, Avisto, Acabar, sonho desapareça, Marimbondos.

Carlos Drummond de Andrade:
Entidades encontradas: J. Pinto Fernandes, Maria, Raimundo, Teresa, Teus, Estados Unidos, Ficaste, rouba, João, Joaquim.

Vinicius de Moraes:
Entidades encontradas: De casa, Oceano, Ulcerai, Onde, Senhor, Amo-te, Enlouquecei, Criação, Meu Senhor, Delirava.

3.3 Dependências Sintáticas

Nesta etapa, foi realizada uma análise de dependências sintáticas, com o fim de extrair relações gramaticais entre as palavras de uma frase. Foi gerada uma árvore sintática do texto.

```
ANÁLISE DE DEPENDÊNCIAS SINTÁTICAS:
Relações entre palavras (Token → Dependência → Head):

eu          →(nsubj   )→ tinha
não         →(advmod  )→ tinha
este        →(det     )→ rosto
rosto       →(obj     )→ tinha
de          →(case    )→ hoje
hoje        →(advmod  )→ rosto
assim       →(advmod  )→ calmo
calmo       →(advcl   )→ tinha
assim       →(advmod  )→ calmo
triste      →(obl     )→ calmo
assim       →(advmod  )→ magro
magro       →(conj    )→ calmo
nem         →(cc      )→ olhos
estes       →(det     )→ olhos
olhos       →(conj    )→ calmo
tão         →(advmod  )→ vazios
vazios      →(amod    )→ olhos
nem         →(cc      )→ lábio
o           →(det     )→ lábio
lábio       →(conj    )→ tinha

ÁRVORE SINTÁTICA (root):

  Raiz: 'tinha'
    └─ eu (nsubj)
    └─ não (advmod)
    └─ rosto (obj)
    └─ calmo (advcl)
    └─ lábio (conj)

  Raiz: 'dei'
    └─ eu (nsubj)
    └─ não (advmod)
    └─ mudança (obj)
    └─ simples (amod)
    └─ ficou (acl:relcl)


SINTAGMAS NOMINAIS (Noun Chunks):
  1. 'eu' (head: eu)
  2. 'este rosto' (head: rosto)
  3. 'amargo' (head: amargo)
  4. 'estas mãos' (head: mãos)
  5. 'força' (head: força)
  6. 'frias' (head: frias)
  7. 'este coração' (head: coração)
  8. 'se' (head: se)
  9. 'esta mudança' (head: mudança)
  10. 'que' (head: que)
```

3.4 Pipeline

Uma pipeline completa foi realizada, com o objetivo de comparar o tempo do spaCy com NLTK. Foi escolhido um poema aleatório, com semente fixa para garantir reprodutibilidade. O NLTK apresentou velocidade maior no poema analisado.

3.5 Análise Completa

Nesta etapa, foi realizada uma análise aprofundada da obra de quatro autores de língua portuguesa — Fernando Pessoa, Sophia de Mello Breyner Andresen, Eugénio de Andrade e Vinicius de Moraes — utilizando o pipeline completo do spaCy com o modelo *pt_core_news_sm.*

A análise foi dividida em quatro seções principais.

Resumo por autor: Para cada autor, foram coletadas métricas gerais sobre o conjunto de seus poemas no dataset, incluindo total de tokens, tamanho do vocabulário único, diversidade de classes gramaticais, quantidade de entidades nomeadas identificadas e média de tokens por poema. Os resultados foram apresentados em tabela e em gráficos de barras comparativos.

Termos mais comuns: Foi levantada a frequência dos lemmas mais recorrentes na obra de cada autor, após remoção de stopwords. Os dez termos mais frequentes de cada autor foram exibidos em gráficos de barras horizontais, permitindo identificar os temas e vocabulários predominantes em cada obra.

Distribuição de POS tags: Foi analisada a distribuição das classes gramaticais (substantivos, verbos, adjetivos, etc.) nos textos de cada autor, possibilitando comparar o perfil sintático de cada um.

Complexidade sintática: Foi calculada a profundidade média das árvores de dependência de cada autor, métrica que indica o grau de complexidade e subordinação sintática presente em seus textos. Autores com maior profundidade média tendem a construir frases mais elaboradas e com maior encadeamento de orações.

4. DISCUSSÃO

É possível observar os resultados entre as diferentes bibliotecas utilizadas, NLTK e spaCy, onde spaCy gerou uma quantia maior de tokens, dado que o spaCy também considera espaços, travessões, hífens e apóstrofos, cada um como um token independente, diferente do NLTK, que considera apenas palavras ou sentenças, tendo regras mais conservadoras. É importante observar que, esses detalhes a mais analisados pelo spaCy são cruciais, quando é realizada a análise de poemas. No POS-TAG, o NLTK é utilizado, porém a biblioteca não fornece suporte para o idioma do português, o que gera uma classificação errônea das classes gramaticais apresentadas. Em comparação, o spaCy fornece suporte em português, tendo um valor maior para análises neste idioma. No NER (Reconhecimento de entidade nomeada) é possível observar bastante irregularidade na detecção de entidades, sendo o autor Carlos Drummond de Andrade o que apresentou maior congruência de entidades. O modelo do spacy, *pt_core_news_sm*, foi treinado utilizando texto jornalístico, o que explica a dificuldade de reconhecimento em poemas literários, já que sua linguagem pode fugir do vocabulário do modelo. Nas

dependências sintáticas, é possível observar uma alta diversidade sintática, explicada pelo uso de diferentes relações e presença de estruturas variadas. Na pipeline, onde fizemos uma comparação geral entre NLTK e spaCy, foi possível observar uma vantagem na velocidade do NLTK. Porém, isso não é algo conclusivo, já que o spaCy utiliza modelos de linguagem, e o NLTK não aplica POS-TAG real, já que não tem suporte ao português. Na análise completa, é possível ver diferenças expressivas entre os quatro autores. **Fernando Pessoa** é o autor analisado com maior número de poemas, respectivamente, 2232 poemas, o que representa a maior parte dos poemas analisados. Na distribuição de POS tags, é possível observar os substantivos (NOUN) sendo a classe mais frequente, seguido de verbos (VERB). Em complexidade sintática, Sophia de Mello Breyner e Eugénio de Andrade apresentam maior profundidade média, o que indica estruturas sintáticas bem elaboradas por parte dos autores.

4.1 Limitações da abordagem

A desproporção entre os autores, evidenciando Fernando Pessoa com 2.232 poemas contra 54 de Vinicius de Moraes, compromete comparações diretas, já que autores com maior volume de obra tendem a apresentar vocabulário mais amplo simplesmente pelo efeito da amostra.

Modelo treinado em texto jornalístico: O *pt_core_news_sm* foi desenvolvido com base em corpus jornalístico, o que limita sua capacidade de lidar com a linguagem poética — marcada por inversões sintáticas, arcaísmos, neologismos e estruturas que fogem da norma culta contemporânea. Isso afeta diretamente a qualidade do NER, da lemmatização e da análise de dependências.

POS-TAG do NLTK: A ausência de suporte ao português no módulo de POS-TAG do NLTK torna essa etapa analiticamente inválida para o contexto do projeto. Os resultados foram gerados com o modelo em inglês, o que classifica incorretamente as classes gramaticais dos tokens portugueses.

5. CONCLUSÃO

Dessa forma, é possível concluir que existem diferenças relevantes entre as bibliotecas NLTK e spaCy, tanto em termos de funcionamento quanto na qualidade das análises geradas. O NLTK apresenta maior velocidade na execução, porém suas limitações, principalmente a ausência de suporte adequado ao idioma português, comprometem a confiabilidade dos resultados, especialmente em tarefas como POS-TAG. Em contrapartida, o spaCy demonstra maior adequação para análises em português, oferecendo suporte mais consistente para tarefas como classificação gramatical, reconhecimento de entidades e análise de dependências. Ainda assim, o modelo utilizado apresenta limitações ao lidar com textos poéticos, devido ao fato de ter sido treinado majoritariamente com textos jornalísticos, o que impacta diretamente a precisão em estruturas mais complexas e não convencionais.

Além disso, a análise dos autores evidenciou diferenças importantes em relação à distribuição gramatical e à complexidade sintática, embora fatores como a desproporção do corpus podem ter influenciado os resultados obtidos.

Portanto, é importante considerar que, apesar das ferramentas de PLN apresentarem bons recursos para análise textual, sua eficácia depende diretamente do

contexto de aplicação, do tipo de texto analisado e da adequação dos modelos utilizados. Como possível continuidade, seria interessante utilizar modelos mais específicos para linguagem literária ou construir um corpus mais equilibrado, visando obter análises mais consistentes.