FACULDADE DE TECNOLOGIA DE OURINHOS – FATEC

RAMON LUIS SANCHES, NICOLLAS GERMANO KRATKY, JOÃO VICTOR NETTO ARAUJO, RAFAEL CARBONERA LIUTE

TASK 1

TF e TF-IDF COM POEMAS PORTUGUESES

OURINHOS

2026

Sumário

1. Introdução 3
2. Metodologia 3
3. Resultados 3
3.1 Top 20 termos mais frequentes (TF) 4
3.2 Bigramas mais frequentes & Top 15 termos por TF-IDF (Global) 5
3.3 Comparação TF vs TF-IDF por autor & Comparação L1 vs L2 5
3.4 Word Clouds 6
3.5 Comparação de Poemas & Mapas Semânticos 7
4. Discussão 10
4.1 Limitações da abordagem 10
5. Conclusão 10

1. INTRODUÇÃO

A presente tarefa prática foi desenvolvida a partir do dataset *the-complete-literary-works-of-fernando-pessoa* retirado do Kaggle, que contém as seguintes colunas: **Title**, **Author**, **Form**, **Text** e **Biblio** representando, respectivamente, o título da obra, o nome do autor, se a obra é poema ou prosa, o conteúdo e referência.

O objetivo deste trabalho é aplicar técnicas de vetorização de texto em um corpus de poemas em língua portuguesa, com ênfase nas obras de Fernando Pessoa e de seus heterônimos.

2. METODOLOGIA

Para o desenvolvimento deste trabalho, serão realizadas as seguintes etapas: inicialmente, será conduzida uma exploração dos dados, com o objetivo de compreender sua estrutura e principais características. Em seguida, será realizada a etapa de limpeza removendo dados inconsistentes e normalizando as colunas e os textos, que serão padronizados em letras minúsculas.

Posteriormente, será aplicado um filtro no conjunto de dados, a fim de selecionar especificamente os poemas atribuídos a Fernando Pessoa e seus heterônimos. Na sequência, será realizado o pré-processamento textual, utilizando técnicas como *stemming*, que reduz as palavras à sua forma radical, e tokenização, responsável por dividir o texto em unidades menores. Após essas etapas, serão aplicadas técnicas de representação textual, como TF (frequência do termo) e TF-IDF (frequência do termo ponderada pela frequência inversa nos documentos).

Por fim, serão empregadas abordagens de análise visual, como gráficos e nuvens de palavras, além da realização de uma análise de similaridade entre poemas, com o objetivo de identificar padrões e relações entre os textos.

3. RESULTADOS

O dataset apresenta boa qualidade após limpeza, com remoção de duplicatas, normalização textual e filtragem, com a tokenização revelando uma redução de 48.03% após remoção de stopwords, indicando alta presença de palavras funcionais no corpus. O stemming reduziu a variabilidade lexical, agrupando variações e aumentando a consistência dos dados mantendo a distribuição de tokens por poema mais concentrada após o pré-processamento, indicando grande densidade semântica.

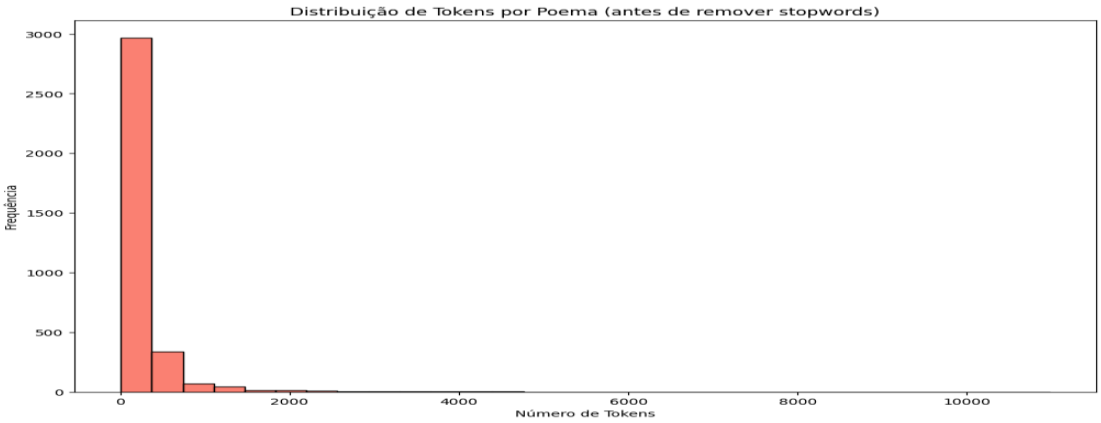

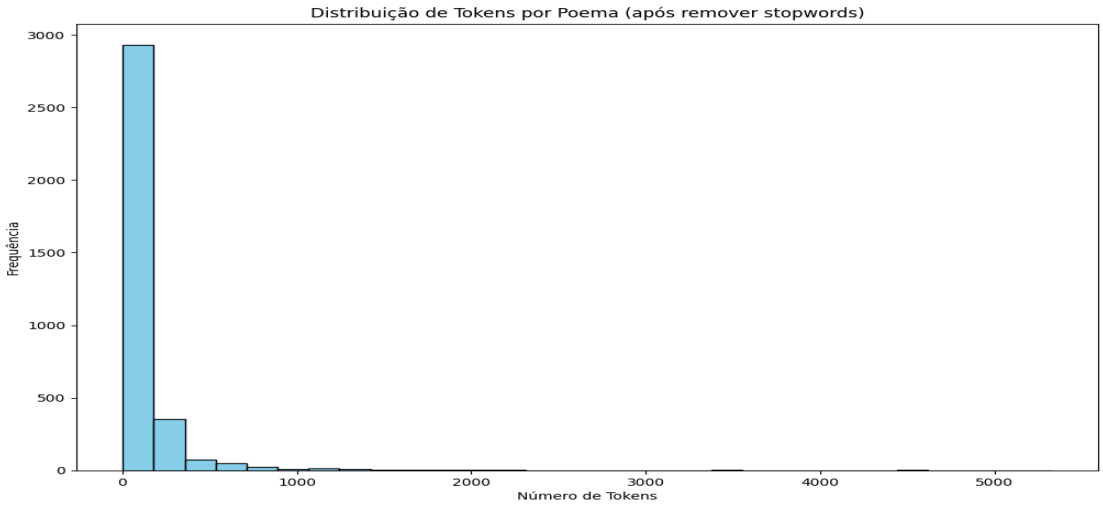

A matriz TF mostrou alta frequência de termos comuns, enquanto o TF-IDF destacou termos mais específicos, isso fica evidente quando olhamos para as nuvens de palavras. A normalização L2 manteve a geometria vetorial adequada para o cálculo de similaridade.

3.1 Top 20 termos mais frequentes (TF)

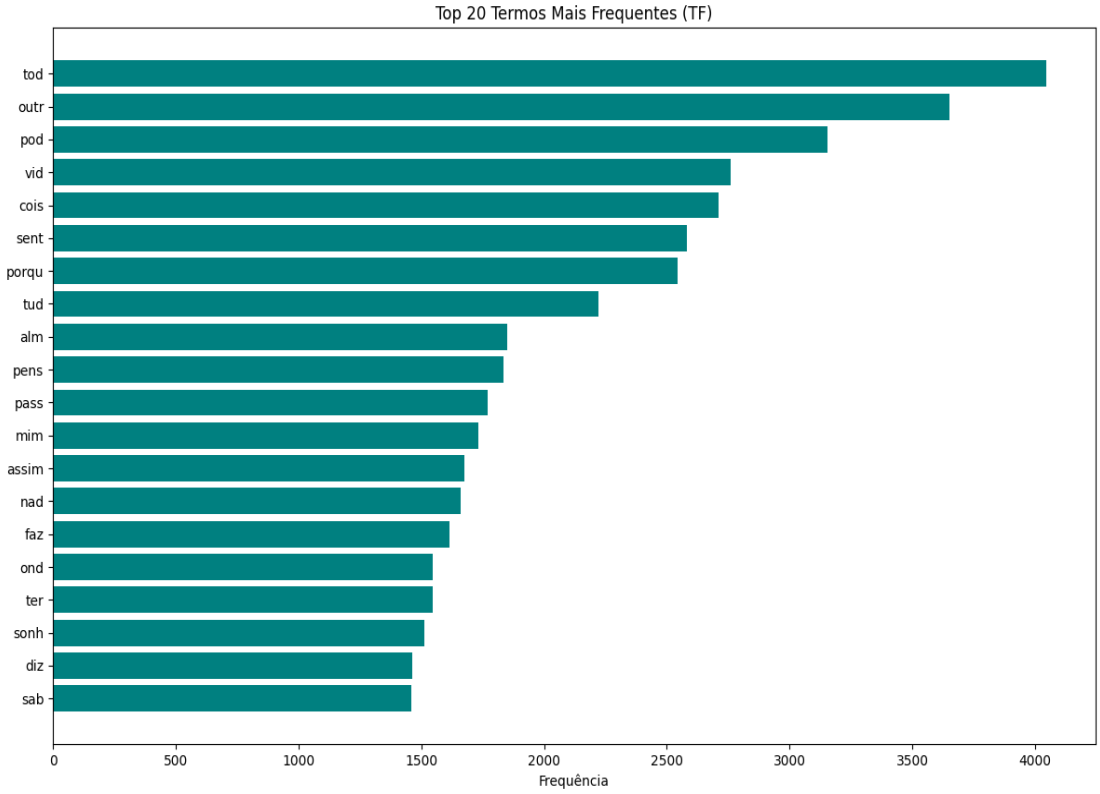

3.2 Bigramas mais frequentes & Top 15 termos por TF-IDF (Global)

```
=== Bigramas Mais Frequentes ===
 1. qualqu cois              : 382
 2. eh eh                    : 218
 3. fern pesso               : 205
 4. tud quant                : 199
 5. pod ter                  : 173
 6. outr cois                : 172
 7. qu diz                   : 159
 8. opin públic              : 154
 9. si própri                : 134
10. outr vez                 : 130
```

```
=== Top 15 Termos por TF-IDF (Global) ===
 1. tod   : 93.691558
 2. vid   : 90.588112
 3. outr  : 86.432801
 4. cois  : 79.140631
 5. sent  : 77.898172
 6. tud   : 76.689151
 7. pens  : 76.450940
 8. mim   : 74.969529
 9. sonh  : 71.988787
10. porqu : 71.958766
11. alm   : 70.333336
12. nad   : 69.055156
13. pod   : 69.034708
14. pass  : 65.348191
15. olh   : 59.359176
```

3.3 Comparação TF vs TF-IDF por autor & Comparação L1 vs L2

```
=== Comparação TF vs TF-IDF por Autor ===

==================================================
AUTOR: Fernando Pessoa
==================================================
Top 10 por TF                  | Top 10 por TF-IDF
-------------------------------------------------
1. porque                      | 1. porque
2. vida                        | 2. vida
3. assim                       | 3. alma
4. tudo                        | 4. tudo
5. pode                        | 5. mim
6. qualquer                    | 6. nada
7. alma                        | 7. assim
8. nada                        | 8. ter
9. ter                         | 9. onde
10. onde                       | 10. pode

==================================================
AUTOR: Álvaro de Campos
==================================================
Top 10 por TF                  | Top 10 por TF-IDF
-------------------------------------------------
1. tudo                        | 1. tudo
2. vida                        | 2. vida
3. mim                         | 3. mim
4. todos                       | 4. nada
5. porque                      | 5. porque
6. nada                        | 6. onde
7. eh                          | 7. ter
8. coisa                       | 8. coisa
9. ter                         | 9. alma
10. alma                       | 10. todos

==================================================
AUTOR: Alberto Caeiro
==================================================
Top 10 por TF                  | Top 10 por TF-IDF
-------------------------------------------------
1. porque                      | 1. porque
2. coisa                       | 2. coisa
3. coisas                      | 3. coisas
4. flores                      | 4. sei
5. mim                         | 5. nunca
6. sei                         | 6. ter
7. sol                         | 7. mim
8. ter                         | 8. sol
9. tudo                        | 9. flores
10. nunca                      | 10. natureza

==================================================
AUTOR: Ricardo Reis
==================================================
Top 10 por TF                  | Top 10 por TF-IDF
-------------------------------------------------
1. vida                        | 1. vida
2. deuses                      | 2. deuses
3. paganismo                   | 3. nada
4. nada                        | 4. porque
5. porque                      | 5. tudo
6. obra                        | 6. onde
7. tudo                        | 7. assim
8. assim                       | 8. alma
9. onde                        | 9. pouco
10. alma                       | 10. sempre

==================================================
AUTOR: Bernardo Soares
==================================================
Top 10 por TF                  | Top 10 por TF-IDF
-------------------------------------------------
1. vida                        | 1. vida
2. tudo                        | 2. tudo
3. porque                      | 3. mim
4. mim                         | 4. porque
5. alma                        | 5. alma
6. sempre                      | 6. nunca
7. nunca                       | 7. coisa
8. sonho                       | 8. sempre
9. coisa                       | 9. ter
10. ter                        | 10. sonho

=== Comparação L1 vs L2 ===
Norma L1 (Manhattan) - Soma de um vetor: 1.000000
Norma L2 (Euclidiana) - Norma de um vetor: 1.000000
```

3.4 Word Cloud TF – Word Cloud TF-IDF

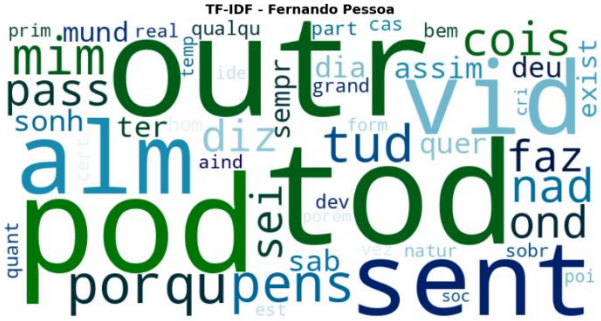

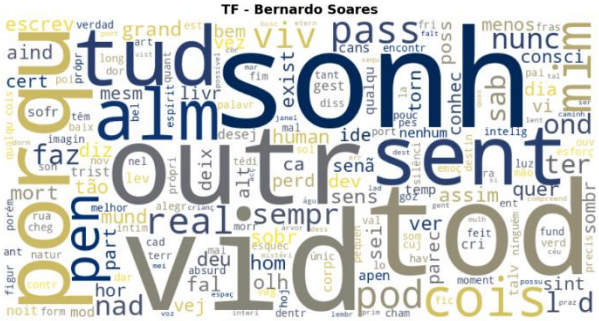

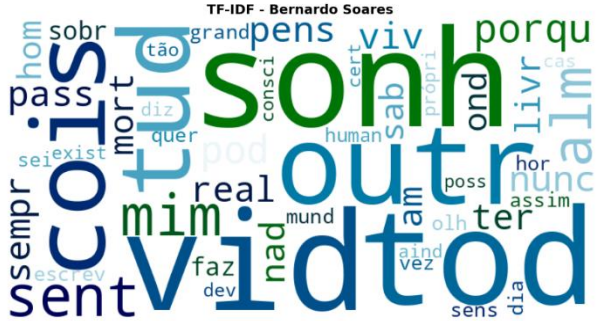

A matriz de similaridade de cosseno evidenciou proximidade entre poemas de um mesmo autor. O PCA conseguiu reduzir a dimensionalidade preservando padrões relevantes do corpus evidenciando dois eixos interpretáveis: **CP1** = (-) lógico vs emocional (+) e **PC2** = (-) concreto vs abstrato (+). Os dados apresentaram variações claras entre autores, tanto em volume quanto em estilo. Essas estatísticas confirmam que o pré-processamento foi eficaz para análise semântica.

3.5 Comparação de Poemas & Mapas Semânticos

```
======================================================================
POEMA DE REFERÊNCIA: Álvaro de Campos
======================================================================
aniversário no tempo em que festejavam o dia dos meus anos eu era feliz e ninguém estava morto na casa antiga até eu fazer anos era uma tradição de há

POEMAS MAIS SIMILARES:

1. [0.2668] Bernardo Soares
   l do d tudo se me evapora a minha vida inteira as minhas recordações a minha imaginação e o que contém a minha personalidade tudo se me evapora contin...

2. [0.2529] Álvaro de Campos
   realidade sim passava aqui frequentemente há vinte anos nada está mudado ou pelo menos não dou por isso nesta localidade da cidade há vinte anos o que...

3. [0.2141] Fernando Pessoa
   a reforma do calendário e as suas consequências comerciais a comissão especial de inquérito à reforma do calendário estabelecida pela sociedade das na...

4. [0.2050] Fernando Pessoa
   o andaime o tempo que eu hei sonhado quantos anos foi de vida ah quanto do meu passado foi só a vida mentida de um futuro imaginado aqui à beira do ri...

5. [0.1930] Fernando Pessoa
   fim brilhai eternamente no tempo astro do mundo em que brilhais voai sem fim nem cansaço aves da terra de que sois aves coro cantai nas árvores das es...
```

```
POEMAS MAIS SIMILARES:

1. [0.4181] Fernando Pessoa
   quando a manhã aparece quando a manhã aparece dizem que nasce alegria isso era se ela viesse até de noite era dia...

2. [0.3013] Ricardo Reis
   ténue como se de éolo a esquecessem a brisa da manhã titila o campo e há começo do sol não desejemos lídia nesta hora mais sol do que ela nem mais alt...

3. [0.2681] Alberto Caeiro
   pouco a pouco o campo se alarga e se doura a manhã extravia se pelos irregulares da planície sou alheio ao espectáculo que vejo vejo o e exterior a mi...

4. [0.2611] Ricardo Reis
   manhã que raias sem olhar a mim sol que luzes sem querer saber de eu ver te é para mim que sois reais e verdadeiros porque é na oposição ao que eu des...

5. [0.2347] Alberto Caeiro
   v há metafísica bastante em não pensar em nada o que penso eu do mundo sei lá o que penso do mundo se eu adoecesse pensaria nisso que ideia tenho eu d...
```

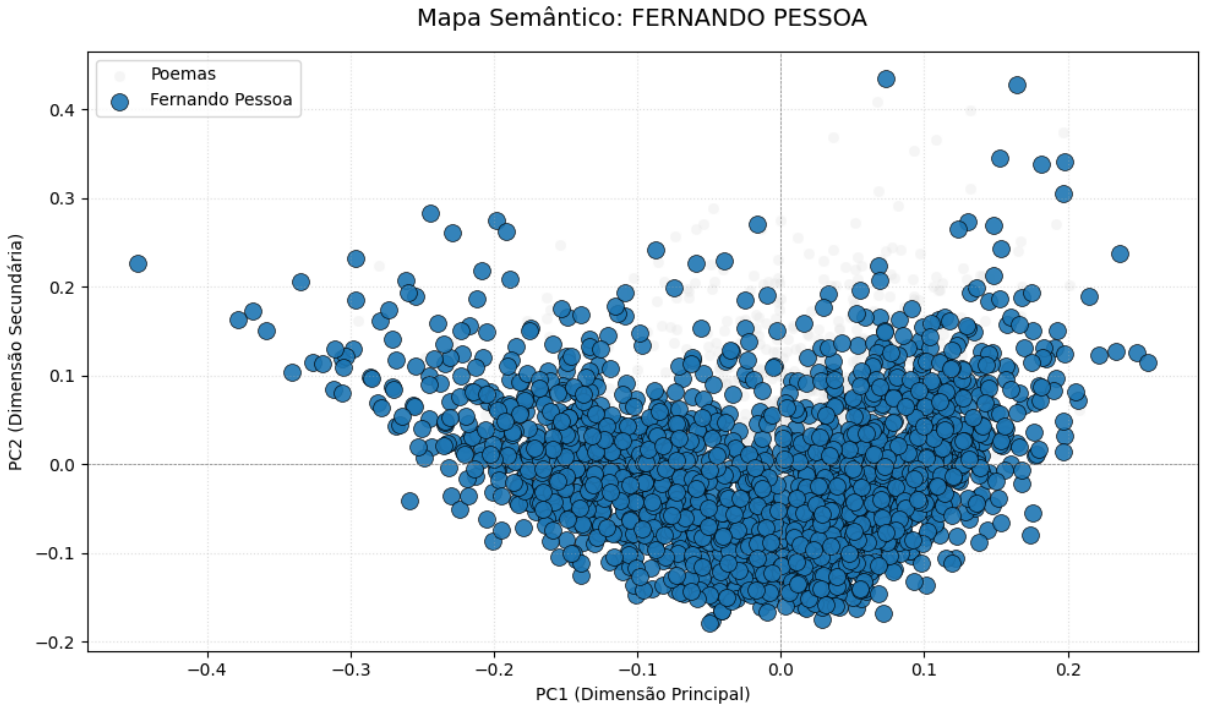

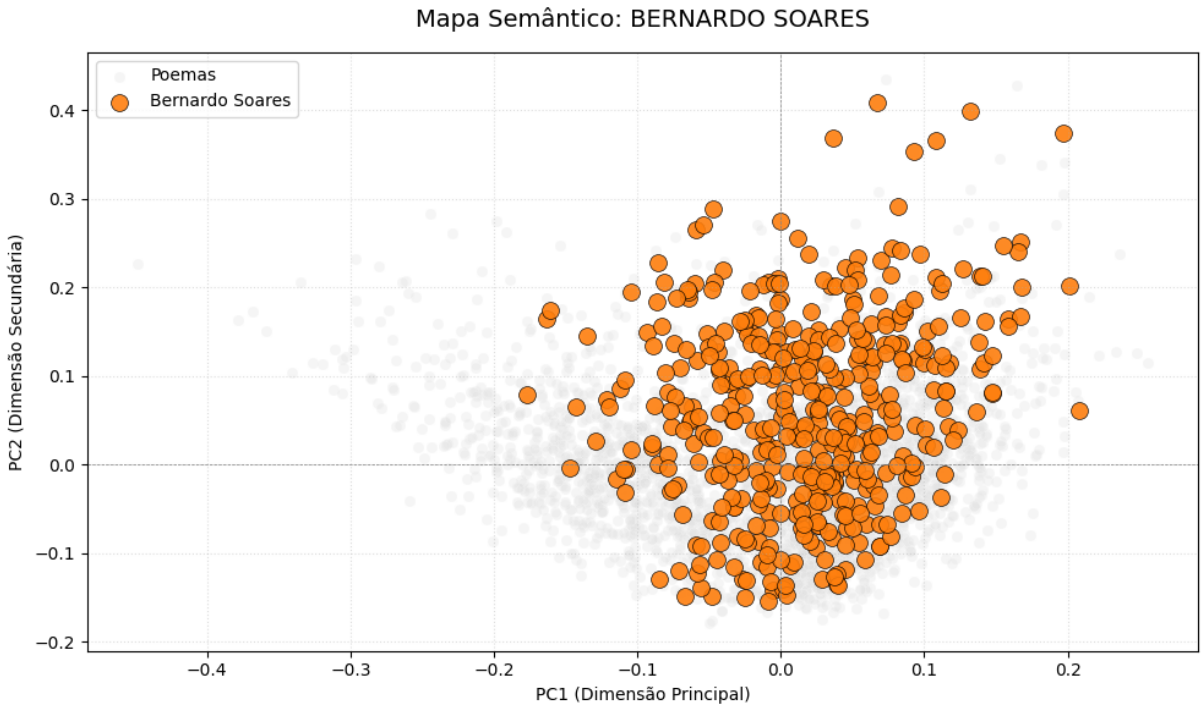
Mapa Semântico: BERNARDO SOARES
Poemas
Bernardo Soares
PC2 (Dimensão Secundária)
PC1 (Dimensão Principal)
0.4
0.3
0.2
0.1
0.0
−0.1
−0.2
−0.4
−0.3
−0.2
−0.1
0.0
0.1
0.2

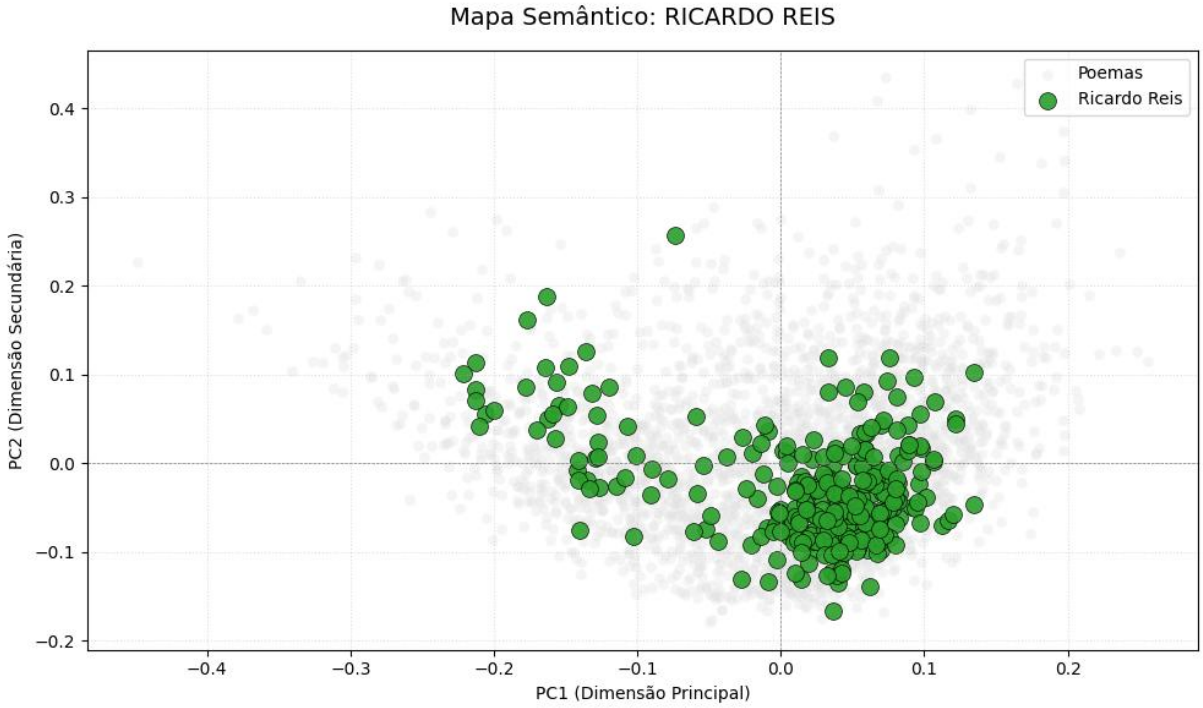
Mapa Semântico: RICARDO REIS
Poemas
Ricardo Reis
PC2 (Dimensão Secundária)
PC1 (Dimensão Principal)
0.4
0.3
0.2
0.1
0.0
−0.1
−0.2
−0.4
−0.3
−0.2
−0.1
0.0
0.1
0.2

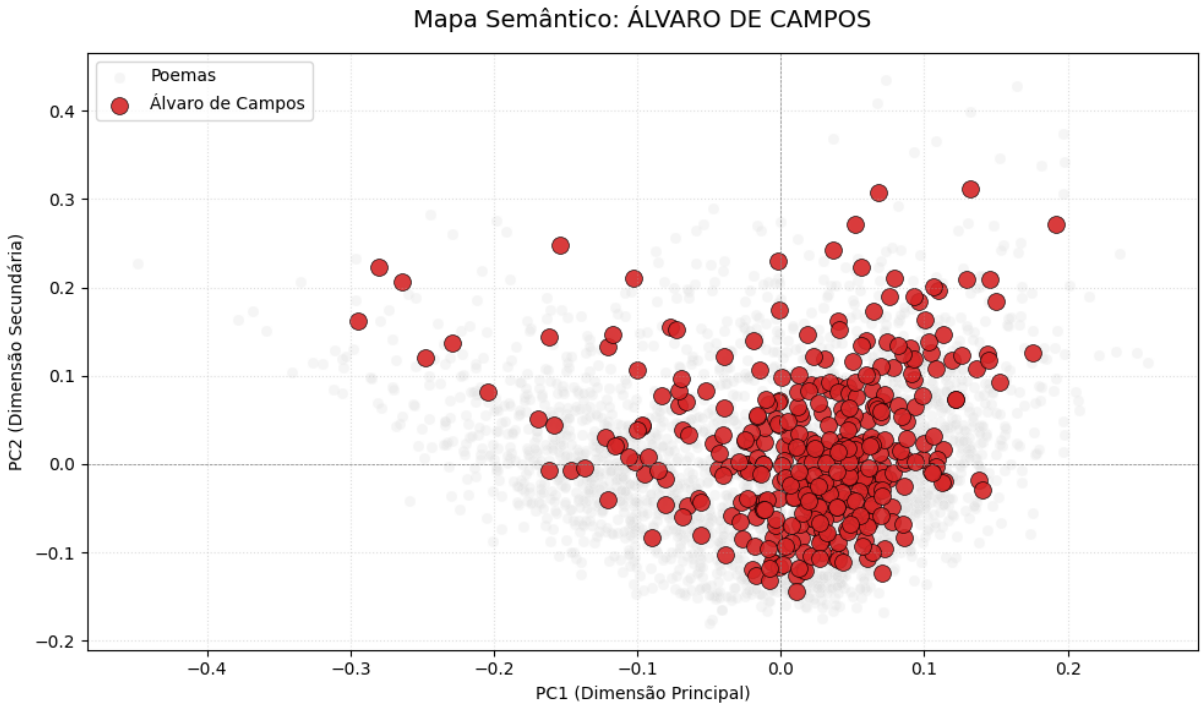
Mapa Semântico: ÁLVARO DE CAMPOS
Poemas
Álvaro de Campos
PC2 (Dimensão Secundária)
PC1 (Dimensão Principal)
0.4
0.3
0.2
0.1
0.0
−0.1
−0.2
−0.4
−0.3
−0.2
−0.1
0.0
0.1
0.2

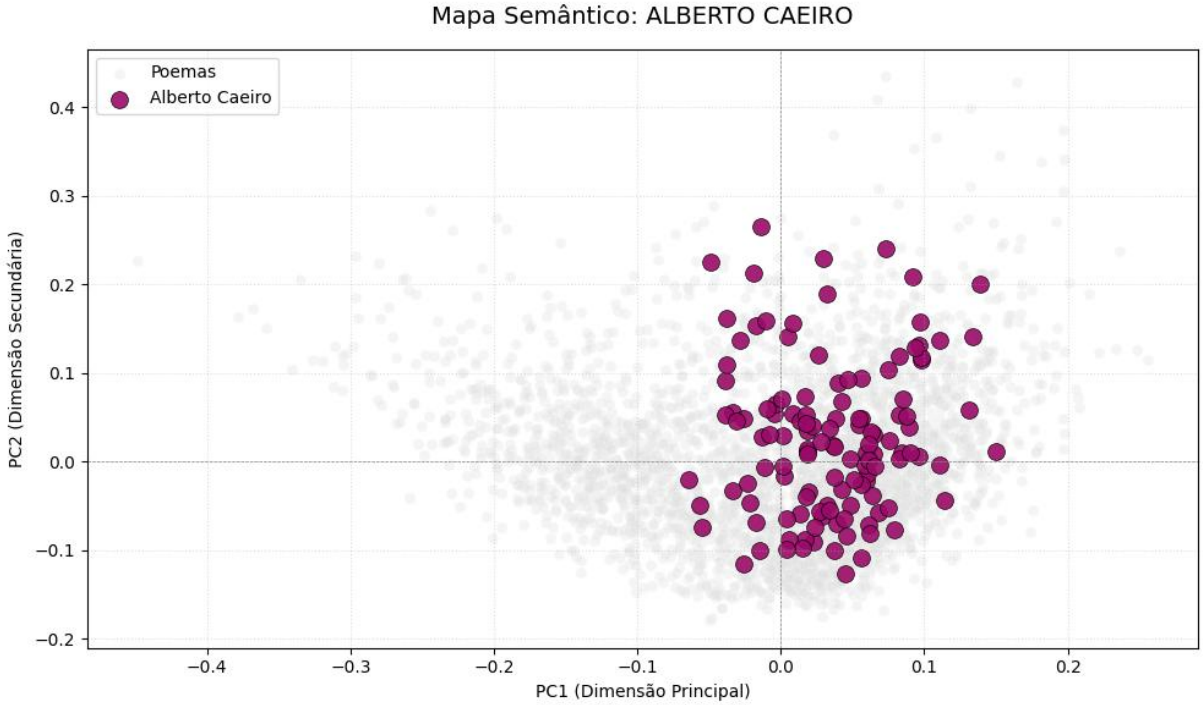
Mapa Semântico: ALBERTO CAEIRO
Poemas
Alberto Caeiro
PC2 (Dimensão Secundária)
PC1 (Dimensão Principal)
0.4
0.3
0.2
0.1
0.0
−0.1
−0.2
−0.4
−0.3
−0.2
−0.1
0.0
0.1
0.2

4. DISCUSSÃO

Fernando Pessoa e Álvaro de Campos ocupam as áreas mais dinâmicas e fragmentadas do mapa, refletindo uma genialidade marcada pela instabilidade vetorial. Enquanto o primeiro é dominado por termos metafísicos, o segundo oscila entre o futurismo e o dilema existencial. Ambos apresentam uma alta amplitude léxica, onde a independência dos vetores TF-IDF traduz visualmente a complexidade de suas crises e a vastidão de seus territórios intelectuais.

Em contraste, Alberto Caeiro e Ricardo Reis formam "clusters" densos, indicando baixa entropia e vocabulários de alta precisão. Caeiro se ancora no quadrante sensorial e imediato, com pontos coesos que priorizam o mundo físico, enquanto Reis mantém uma disciplina em um centroide sentimental que não chega aos extremos. Bernardo Soares completa o mapa lexical flutuando no eixo da introspecção, ocupando o território abstrato e distanciando-se do concreto, através de uma densa nuvem de subjetividade.

4.1 Limitações da abordagem

A principal limitação dessas abordagens é o uso de modelos (TF-IDF), que ignoram a ordem das palavras e a estrutura sintática, perdendo a profundidade semântica e o contexto, essenciais para a poesia. O stemming e a remoção de stopwords podem descaracterizar termos líricos com forte peso emocional. Além disso, a similaridade de cosseno baseia-se apenas na sobreposição de vocabulário, sendo incapaz de identificar conexões temáticas, sentimentos com as mesmas raízes

5. CONCLUSÃO

Os principais aprendizados mostram que o pré-processamento é fundamental para garantir qualidade na análise textual, pois a remoção de stopwords reduz ruídos e aumenta a densidade semântica, enquanto o stemming unifica variações de palavras e melhora a generalização. Observa-se que a frequência simples (TF) não é suficiente para capturar significado, sendo o TF-IDF mais eficaz ao evidenciar relevância e identidade lexical dos autores. Cada poeta apresenta uma assinatura linguística própria, detectável por métodos estatísticos, e a similaridade de cosseno se mostrou eficiente para medir proximidade semântica entre textos. A aplicação de PCA facilita a visualização de padrões complexos em um espaço reduzido. Por fim, fica claro que técnicas de PLN complementam análises tradicionais com evidências objetivas.